FICHE DE LECTURE / SCIENCE

AlphaZero contre Stockfish : la révolution de l'intelligence artificielle aux échecs

AlphaZero vs Stockfish 2017 : apprentissage par renforcement, réseau de neurones, style de jeu révolutionnaire. Comment l'IA a changé la compréhension des échecs.

COMPRENDRE. NUANCER. APPROFONDIR.

Le passage, dans son contexte

Cette fiche reprend un passage du dossier ci-dessous. Le texte complet et sa bibliographie permettent d’en approfondir le contexte.

AlphaZero contre Stockfish : la révolution de l'intelligence artificielle aux échecs

La comparaison entre AlphaZero et Stockfish permet d'examiner différentes manières d'associer recherche, évaluation et apprentissage dans un programme d'échecs. L'intérêt ne se réduit pas au résultat d'un match : il porte aussi sur les méthodes employées et les conditions de la comparaison.

Pour comprendre ce que les parties publiées montrent, il faut distinguer les décisions visibles sur l'échiquier, le fonctionnement des programmes et les conclusions permises par le protocole. Une sélection de parties peut éclairer une méthode sans suffire à caractériser tous ses avantages.

L'architecture d'AlphaZero

Pour comprendre pourquoi AlphaZero représente une rupture, il faut comprendre ce qu'il fait, et ce qu'il ne fait pas.

AlphaZero est un système de deep reinforcement learning (apprentissage par renforcement profond). Il combine deux technologies :

Un réseau de neurones profond qui prend en entrée la position de l'échiquier et produit deux sorties : une distribution de probabilité sur tous les coups légaux (la "policy head" : quels coups semblent prometteurs), et une valeur entre -1 et +1 estimant l’issue du point de vue du joueur au trait (la « tête de valeur »).

La recherche arborescente Monte Carlo (MCTS) qui utilise le réseau de neurones pour guider la recherche. Elle sélectionne des chemins jusqu’aux feuilles de l’arbre exploré ; le réseau y fournit une évaluation qui remonte vers la racine. Ces simulations ne sont pas toutes jouées jusqu’au mat. La recherche alpha-bêta de Stockfish est elle aussi sélective : l'opposition n'est pas entre un programme qui choisit ses variantes et un autre qui calculerait absolument tout.

Le réseau apprend sans exemples de parties humaines, sans bibliothèque d'ouvertures et sans base de finales. Cela ne signifie pas que le système émerge sans conception humaine : les chercheurs définissent les règles, la représentation des positions, l'architecture du réseau et la procédure d'apprentissage. L'absence d'une fonction d'évaluation écrite à partir de concepts échiquéens doit être distinguée de l'absence de toute connaissance utilisée pour construire le programme.

Il a joué 44 millions de parties contre lui-même en neuf heures environ, ajustant les paramètres du réseau au fil de l'entraînement. Cette durée mobilise un matériel considérable : 5 000 TPU de première génération génèrent les parties et 16 TPU de deuxième génération entraînent le réseau dans le protocole de 2018, contre 64 pour cette dernière tâche dans le préprint de 2017. Il faut distinguer ce coût d'apprentissage du matériel employé ensuite pour jouer un match. Publications de 2017 et 2018, méthodes et tableau S3.

Trois nombres qui ne répondent pas à la même question

La probabilité associée à un coup, la valeur d'une position et le nombre de visites dans l'arbre peuvent sembler interchangeables. Ils servent pourtant à des opérations distinctes. Voici un exemple numérique inventé pour l'explication, qui ne reproduit aucune sortie réelle d'AlphaZero.

Supposons que le réseau attribue trois probabilités initiales : 0,60 au coup A, 0,30 à B et 0,10 à C. Cela ne signifie pas que A gagne dans 60 % des cas. Ces nombres forment une distribution sur les coups et orientent la recherche. Une partie importante du travail consiste justement à examiner ce que les réponses adverses font à ces candidats.

Supposons ensuite que la recherche aboutisse à 18 visites pour A, 70 pour B et 12 pour C. Le candidat initialement le plus favorisé n'est plus le plus visité. Ce scénario illustre comment le réseau et l'exploration peuvent produire des préférences différentes. Les nombres ont été choisis pour rendre cette distinction visible ; ils ne décrivent ni la formule de sélection complète ni une répartition fixe à respecter.

La valeur répond encore à une autre question. Avec la convention victoire = +1, nulle = 0 et défaite = −1, une répartition hypothétique de 40 % de victoires, 50 % de nulles et 10 % de défaites aurait une valeur moyenne de 0,40 − 0,10 = 0,30. Une valeur de 0,30 n'est donc pas, à elle seule, une probabilité de victoire de 30 %. Le réseau décrit dans l'article produit une estimation scalaire ; cette décomposition est notre illustration arithmétique, pas trois probabilités qu'il afficherait nécessairement.

Le point de vue compte également. Une position favorable au joueur au trait devient défavorable à son adversaire. Lorsqu'on propage des valeurs dans une recherche alternant les deux camps, il faut conserver cette convention. Oublier ce changement reviendrait, dans une analyse humaine, à considérer le meilleur coup adverse comme s'il cherchait à nous aider. La description algorithmique de 2017 distingue la politique du réseau, les statistiques de recherche et le résultat qui sert à l'apprentissage.

Le match : 28-0-72

Dans le match de décembre 2017, AlphaZero a joué 100 parties contre Stockfish 8, la version choisie pour cette comparaison. Résultat : 28 victoires pour AlphaZero, 72 nulles, 0 défaite. Dans le détail : avec les Blancs, 25 victoires et 25 nulles ; avec les Noirs, 3 victoires et 47 nulles.

Ce n'était pas une cadence classique : chaque programme disposait d'une minute de réflexion fixe par coup. Cette condition empêche de répartir une réserve globale de temps en accordant davantage de réflexion à certains coups critiques. Le résultat doit donc être lu avec cette restriction de la gestion du temps.

L'absence de défaite dans cet échantillon est un résultat du match, pas une preuve d'invincibilité. Les parties publiées permettent d'examiner des idées positionnelles, mais leur sélection ne suffit pas à décrire toutes les victoires ni toutes les positions où les programmes diffèrent.

Des critiques légitimes existent sur les conditions du match :

Stockfish tournait sans base de finales et sans bibliothèque d'ouvertures • Son espace de hachage était limité à 1 Go, très peu pour 64 threads • La cadence

d'une minute par coup neutralisait sa gestion du temps • Le matériel d'AlphaZero (TPU) n'est pas directement comparable aux CPU de Stockfish

La publication évaluée par les pairs dans Science, en décembre 2018, présente un protocole différent : 1 000 parties, 3 heures par partie plus 15 secondes par coup, 44 cœurs pour Stockfish, et la version de Stockfish championne du TCEC 2016.

AlphaZero remporte également ce match : 155 victoires, 6 défaites, 839 nulles sur 1 000 parties, soit environ 57,5 % du score. Il bat par ailleurs Stockfish dans les matchs commençant depuis chacune des 12 ouvertures humaines retenues, dans ces conditions expérimentales ; les essais avec handicap de temps doivent être distingués de ce résultat.

Pour calculer le score de 2017, compte une victoire comme un point et une nulle comme un demi-point : 28 + 72 ÷ 2 = 64 points sur 100. En 2018, le même calcul donne 155 + 839 ÷ 2 = 574,5 points sur 1 000, soit 57,45 %. Comparer seulement « 28 à 0 » et « 155 à 6 » fait disparaître la place des nulles. Cependant, la différence entre 64 % et 57,45 % ne mesure pas isolément un changement de force : le nombre de parties, la cadence et les configurations changent aussi.

Les chiffres de vitesse changent aussi d'un papier à l'autre, et il vaut la peine de les citer ensemble sans les mélanger : 80 000 positions par seconde contre 70 millions en 2017, 60 000 contre 60 millions en 2018. Dans les deux cas, le même ordre de grandeur, un rapport proche de 1 à 1 000.

Ces chiffres arrondis ne décrivent pas des opérations identiques. Évaluer une position avec un réseau profond et la traiter dans la recherche de Stockfish n'ont pas le même coût. Le nombre de positions par seconde ne permet donc pas de conclure qu'un système consomme mille fois moins d'énergie ou serait mille fois plus efficace. Il faut définir la ressource que l'on compare et mesurer celle-ci.

Prolonger la lecture

Relis le dossier complet pour retrouver les autres arguments, les exemples et les références citées. Cette fiche porte sur un angle précis ; elle ne remplace pas l’ensemble de l’article.

Ouvrir le dossier complet sur Blog d’un Gaucher

https://blogdungaucher.com/fr/blog/echecs-alphazero-stockfish/